

온디바이스 AI 경량화 이론 및 에지 디바이스 하드웨어 검증

1. 서론 (Introduction)

- **연구 배경:** 본 연구자의 주 전공 분야는 RF 및 아날로그 회로설계(Circuit Design)로 고차원 소프트웨어 알고리즘 및 시스템 레벨의 AI 최적화 기법에 대한 사전 배경지식이 없는 상태에서 본 연구를 착수함.
- **연구 목적:** 무거운 서버 중심의 AI 알고리즘 패러다임에서 벗어나 자원이 제한된 에지 하드웨어 단에 모델을 최적화하여 탑재하는 '온디바이스 AI'의 하드웨어 제약 조건을 이해하고, 핵심 경량화 기법인 정수 양자화(Quantization)의 효용성을 정량적 데이터로 실증함.

2. 주요 학습 내용 및 이론적 배경 (Theoretical Background)

- **에지 배포 환경의 제약 조건 분석:** 서버 ML 환경이 처리량(Throughput)과 연산 정밀도 극대화에 집중하는 반면, 온디바이스 AI 환경은 지연 시간(Latency), 가용 메모리 용량(Memory Footprint), 전력 소비량(Power Consumption) 등의 하드웨어 물리적 제약 조건을 최우선 제약 수식으로 설정함.
- **모델 경량화 알고리즘 메커니즘:**
 - **가지치기(Pruning):** 모델 내부의 가중치(Weight) 중 유효성이 낮은 파라미터를 속아내어 연산 복잡도를 줄이는 기법.
 - **양자화(Quantization):** 32 비트 실수형(FP32) 가중치 데이터를 특정 스케일 팩터와 제로 포인트를 이용해 8 비트 정수형(INT8)으로 매핑하는 기술. 데이터 대역폭 압축 및 연산 유닛(ALU)의 전력/시간 효율 개선의 핵심 기법임.

3. 개인 과제 실습 구성 (Experimental Setup)

- **검증 단말 스펙:** 싱글 보드 컴퓨터(SBC)인 라즈베리파이 5 를 메인 프로세서로 채택하고 웹캠 센서를 연동함.
- **타겟 파이프라인:** 실시간 입력 영상 내 손 형태를 감지하여 가위·바위·보 클래스로 분류하고, 위치 추론 결과를 화면에 바운딩 박스로 표시하는 오브젝트 디텍션(Object Detection) 시스템 구축.
- **이식 및 변환 프로세스:** PC 환경에서 빌드된 원본 Keras 모델(.h5)을 에지 전용 런타임 포맷인 텐서플로우 라이트(.tflite) 형식으로 변환함. 정확도 보존형 실수 모델(FP32)과 최적화형 정수 모델(INT8) 두 가지 버전을 준비하여 기기에 자동 이식함.
- **시연 결과:** 단말 환경에서의 실시간 정상 추론 작동을 검증 완료함 (시연 데이터 레코드: <https://www.youtube.com/shorts/qmfU3LCvc9k>).

4. 정량적 성능 평가 및 하드웨어 리소스 분석

실제 라즈베리파이 5 단말 환경에서 benchmark_rps_ssd_lite_tflite.py 스크립트를 구동하여 런타임 리소스를 실시간 모니터링한 정량적 비교 지표는 다음과 같음.

[표 1] FP32 기본 모델 vs INT8 정수 양자화 모델 성능 비교

평가 항목 (입력 스펙: 64×64×3)	FP32 기본 모델 (fp32.tflite)	INT8 양자화 모델 (int8.tflite)	변동 지표 및 효과 분석
모델 파일 용량 (Size)	115,920 Bytes	36,736 Bytes	68.3% 감소 (메모리 대역폭 점유 최적화)
평균 추론 지연 시간 (Latency)	1.22 ms	1.26 ms	0.96 배 (연산 오차 범위 내 동등 수준 유지)
CPU 사용률 (CPU Pct)	221.0%	181.0%	40.0%p 감소 (하드웨어 연산 부담 완화)
실제 RAM 점유량 (RSS)	42.31 MB	42.14 MB	0.17 MB 감소 (환경적 오버헤드 지배적)

[지표별 공학적 원인 분석 (Engineering Analysis)]

- 용량 최적화 (Size -68.3%):** 가중치를 저장하는 데이터 정밀도가 32 비트 실수에서 8 비트 정수로 축소됨에 따라 정확히 이론적 압축률에 준하는 용량 절감 효과를 달성함. 단말 내 스토리지 용량 확보에 매우 유효함.
- 지연 시간 역전 현상 (Latency 0.96x):** 정수 양자화 적용 시 연산 속도 향상이 일반적이거나, 본 실습 모델(rps_ssd_lite)은 입력 해상도가 64x64x3 으로 극도로 소형화된 엣지 모델임. 이로 인해 순수 가중치 연산 시간보다 입력층과 출력층에서 발생하는 데이터 정밀도 변환(Quantize/Dequantize) 오버헤드가 더 크게 작용하여 미세하게 지연이 발생한 것으로 분석됨.
- CPU 로드 감소 (CPU Pct -40.0%p):** 복잡한 부동소수점 연산 유닛 대신 전력 및 사이클 소모가 적은 8 비트 정수 연산 유닛(NEON 벡터 명령어 집합 등)이 활성화되면서 하드웨어 내부 연산 부하가 대폭 경감됨을 증명함. 단말의 발열 및 전력 제어에 긍정적 지표임.

4. RAM 점유 평탄화 (RSS 메모리 유지): 모델 순수 용량이 약 80KB
압축되었음에도 전체 프로세스 점유량(RSS)이 42MB 선에서 정체된 원인은,
프로세스 초기 구동 시 로드되는 Python 인터프리터, NumPy, OpenCV, TFLite
런타임 스택의 기본 시스템 오버헤드가 지배적(Dominant)이기 때문인 것으로
판명됨.

5. 결론 (Conclusion)

본 연구를 통해 회로설계 전공자 관점에서도 AI 모델의 최적화 공정이 하드웨어
단에 미치는 물리적 영향력을 수치로 실증할 수 있었음. 온디바이스 배포를
성공시키기 위해서는 단일 알고리즘의 정확도나 가중치 용량뿐만 아니라, 시스템
구동 환경 오버헤드와 칩셋 내부의 연산 변환 지연 메커니즘을 통합적으로
스케줄링해야 최적의 하드웨어·소프트웨어 Co-design 을 달성할 수 있음을
확인하였음.